


Proyecto de Fin de Módulo: Flujo de Datos con Azure

De SQL Server local a Lakehouse, Power BI y ML




El Viaje del Dato: Una Visión General del Flujo

Objetivo

Demostrar un flujo de datos completo, desde la ingesta inicial en un entorno local hasta su consumo para análisis y Machine Learning en la nube de Azure.

Fases del Proyecto

1. **Fundación:** Migración de datos desde un SQL Server local a Azure SQL Database.
2. **Orquestación:** Extracción y carga de datos en un Data Lake (ADLS Gen2) usando Azure Data Factory.
3. **Inteligencia:** Transformación y modelado de datos en un Lakehouse con Azure Databricks.
4. **Consumo:** Explotación de los datos a través de Power BI para visualización y Azure ML para modelos predictivos.



Fase 1: El Origen – La Base de Datos Local en SQL Server

Objetivo

Crear una base de datos relacional local como fuente de datos inicial.

Herramienta

SQL Server Management Studio (SSMS) conectado a una instancia local (`localhost\SQLEXPRESS`).

Acciones Realizadas

- Creación de la base de datos `DBLocalProyecto`.
- Definición de la estructura con tres tablas principales: `Clientes`, `Productos` y `Ventas`.
- Inserción de datos de ejemplo para simular un entorno transaccional real.

```
CREATE TABLE Clientes (  
    IdCliente INT IDENTITY(1,1) PRIMARY KEY,  
    Nombre NVARCHAR(100) NOT NULL,  
    Segmento NVARCHAR(50) NOT NULL,  
    Ciudad NVARCHAR(100) NOT NULL,  
    Pais NVARCHAR(100) NOT NULL,  
    FechaAlta DATE NOT NULL  
);
```



Fase 2: La Migración a la Nube con 'Generate Scripts'

Objetivo

Replicar la base de datos local en una base de datos 'DBProyectoClase' en Azure SQL.

Herramienta Clave

Asistente "Generate Scripts" de SQL Server Management Studio.



Punto de Aprendizaje

El script generado incluye la sentencia `USE [DBLocalProyecto]`, que produce un error en Azure SQL. Se explica que este error es informativo y no impide la correcta creación de las tablas y la inserción de los datos, ya que la conexión en SSMS ya apunta a la base de datos de destino correcta.

Fase 3: Asegurando el Acceso a Azure SQL Database

Objetivo


Permitir la conexión desde nuestra máquina de desarrollo (con SSMS) al servidor lógico de Azure SQL.

Concepto Clave

Un servidor lógico en Azure (`srv-proyecto-clase`) actúa como un punto de administración central para las bases de datos y gestiona el acceso a través de reglas de firewall.

Acciones Realizadas

- En el portal de Azure, se navega a la sección "Networking" del servidor SQL.
- Se añade una regla de firewall que permite explícitamente la dirección IPv4 pública del desarrollador.



Fase 4: Construyendo la Tubería de Datos con Azure Data Factory

Objetivo

Crear el servicio de orquestación y establecer la conexión con nuestra base de datos de origen en Azure SQL.

Acciones Realizadas

- **Creación de ADF:** Se despliega un recurso Azure Data Factory (`adf-proyecto-clase`) desde el portal de Azure.
- **Creación de Linked Service:** Dentro de ADF Studio, se configura un 'Linked Service' (LS_AzureSQL_Origen) para conectar con la base de datos `DBProyectoClase`.



Punto de Aprendizaje: ¡Otro Firewall!

Al probar la conexión, surge un error de IP no permitida. Esto se debe a que Azure Data Factory utiliza su propio rango de direcciones IP (del Integration Runtime) para conectarse. Estas IPs también deben ser añadidas a las reglas del firewall de Azure SQL para permitir el acceso.


Fase 5: Preparando el Destino – El Azure Data Lake

Objetivo

Configurar un almacenamiento optimizado para análisis a gran escala y conectar ADF a este destino.

Acciones Realizadas

- Storage Account: Se crea una cuenta de almacenamiento (`stproyectoclase`) con la opción 'Hierarchical namespace' habilitada, convirtiéndola en un ADLS Gen2.
- Contenedor: Dentro de la cuenta, se crea un contenedor llamado `datalake`.
- Linked Service de Destino: Se configura un segundo Linked Service en ADF (LS_ADLS_StProyectoClase) que apunta al Data Lake, usando una 'Account Key' para la autenticación.



Fase 6: Definiendo los Puntos de Conexión – Los Datasets

Objetivo

Abstraer las tablas de origen y las rutas de destino en objetos reutilizables dentro de ADF, que actúan como punteros a los datos.

Datasets de Origen (Azure SQL)



Datasets de Destino (Parquet en ADLS)



Fase 7: La Autopista en Acción – El Pipeline de Copia

Objetivo


Automatizar la transferencia de datos desde Azure SQL a nuestro Data Lake.

Componentes del Pipeline `SQL\_Delta`

- **Actividades 'Copy Data':** Se añade una actividad de copia por cada tabla (`Clientes`, `Productos`, `Ventas`).
- **Source:** Cada actividad usa el Dataset SQL correspondiente (ej. `DS\_SQL\_Ventas`).
- **Sink:** Cada actividad apunta al Dataset Parquet de destino (ej. `DS\_Delta\_Ventas`).

Ejecución y Monitoreo

El pipeline se publica ('Publish all') y se ejecuta ('Trigger now'). El éxito de la operación se verifica en la pestaña 'Monitor' de ADF.





Fase 8: El Cerebro – Configurando Azure Databricks

Objetivo

Preparar el entorno de computación y análisis avanzado para procesar los datos que han aterrizado en el Data Lake.

Acciones Realizadas

- **Workspace:** Se crea un workspace de Azure Databricks (adb-proyecto-clase'). Este es nuestro entorno de trabajo unificado.
- **Clúster:** Dentro del workspace, se configura y se inicia un clúster 'All-purpose' llamado 'cluster-proyecto'. Este clúster proporciona la potencia de cómputo necesaria para el desarrollo interactivo en notebooks.



Fase 9: Acceso Seguro y Centralizado con Secret Scopes

Objetivo

Almacenar de forma segura las credenciales (como la clave de la cuenta de almacenamiento) para que Databricks pueda acceder al Data Lake sin exponerlas directamente en el código del notebook.


Concepto Clave

Un "Secret Scope" (`mi-scope`) es un contenedor seguro para secretos, funcionando como una caja fuerte digital.

Proceso

- Se crea el scope `mi-scope`.
- Se guarda la clave de la cuenta de almacenamiento con el nombre `adls-key` dentro del scope.
- En los notebooks, se recupera la clave de forma segura.

```
storage_key = dbutils.secrets.get(  
    scope="mi-scope",  
    key="adls-key"  
)
```




Fase 10: De Ficheros a Tablas – Creando el Lakehouse

Objetivo

Convertir los datos brutos del Data Lake, almacenados como ficheros Parquet, en tablas gestionadas, optimizadas y consultables directamente con SQL.

Resultado

Los datos ahora son parte del Lakehouse, accesibles a través de consultas SQL y organizados en el Unity Catalog.



Fase 11: Visualizando los Resultados con Power BI

Objetivo


Conectar Power BI Desktop directamente al Lakehouse para el análisis interactivo y la creación de informes de negocio.

Proceso de Conexión

- **Punto de Conexión:** Se utiliza un 'SQL Warehouse' en Databricks, un motor de cómputo optimizado para consultas de BI.
- **Credenciales:** Se obtiene el 'Server hostname', 'HTTP path' y un 'Personal Access Token' desde Databricks.
- **Conector:** En Power BI, se utiliza el conector nativo 'Azure Databricks' para introducir los detalles de conexión.

Resultado


Las tablas del Lakehouse (`delta\_clientes`, `delta\_productos`, `delta\_ventas`) aparecen en el Navegador de Power BI, listas para ser cargadas y visualizadas.



Fase 12: Potenciando los Datos con Machine Learning en Databricks

Objetivo

Utilizar las mismas tablas del Lakehouse como fuente para entrenar, evaluar y registrar un modelo predictivo, completando el ciclo de vida de ML dentro de Databricks.



Fase 13: Extendiendo el Alcance a Azure Machine Learning

Objetivo


Hacer que los datos del Data Lake estén disponibles para experimentos en el workspace de Azure Machine Learning (`aml-proyecto-clase`), garantizando una única fuente de verdad.

Proceso de Conexión

- **Datastore:** Se crea un 'Datastore' en Azure ML (`almacen\_proyecto`) que apunta a nuestra cuenta de almacenamiento `stproyectoclase`.
- **Data Asset:** Se registra un 'Data Asset' (`lakehouse\_asset\_ventas`) que referencia una ruta específica dentro del datastore (ej. `bronze/ventas/`).

Uso

Este Data Asset puede ser seleccionado directamente como fuente de datos para entrenar modelos con 'Automated ML' o en notebooks de Azure ML.




El Flujo Completo: De Dato Crudo a Valor Accionable


Resumen del Viaje


Hemos transformado datos de una base local aislada en un activo centralizado y seguro en la nube, listo para ser consumido por toda la organización.

Logros Clave

 Se estableció una fuente de datos única y fiable en Azure (Lakehouse).

 Se construyó una tubería de datos automatizada y robusta (ADF).

 Se habilitó el análisis de negocio a través de informes interactivos (Power BI).

 Se demostró la capacidad de generar modelos predictivos avanzados (Databricks ML y Azure ML).

Conclusión

Este proyecto implementa una arquitectura de datos moderna y escalable, demostrando el poder de integrar los servicios de Azure para convertir datos en conocimiento y acción.

